

Deteksi Tumor Otak dengan Segmentasi K-Means dan Klasifikasi Menggunakan Algoritma K-Nearest Neighbor yang dimodifikasi

Putri Aulia Rahmah ¹, Christofarel Rumana Putra ², Silvia ³, Elly Matul Imah ⁴

¹Fakulta Matematika dan Ilmu Pengetahuan Alam Universitas Negeri Surabaya, Surabaya, 60231, Indonesia, email: 25032014052@mhs.unesa.ac.id

²Fakulta Matematika dan Ilmu Pengetahuan Alam Universitas Negeri Surabaya, Surabaya, 60231, Indonesia, email: 25032014007@mhs.unesa.ac.id

³Fakulta Matematika dan Ilmu Pengetahuan Alam Universitas Negeri Surabaya, Surabaya, 60231, Indonesia, email: 25032014006@mhs.unesa.ac.id

⁴Fakulta Matematika dan Ilmu Pengetahuan Alam Universitas Negeri Surabaya, Surabaya, 60231, Indonesia, email: ellymatul@unesa.ac.id

Corresponding Author: Putri Aulia Rahmah

INTISARI — Tumor otak adalah pertumbuhan sel abnormal yang terbentuk di dalam otak atau komponen di sekitarnya. Kondisi ini diklasifikasikan menjadi jinak (non-kanker) dan ganas (kanker). Penggunaan *Magnetic Resonance Imaging* (MRI) saat ini menjadi modalitas standar dalam diagnosis penyakit ini, namun analisis citra medis secara manual membutuhkan waktu yang lama, keahlian khusus, serta bersifat subjektif. Selain itu, batas tumor yang tidak jelas dan struktur heterogen sering menimbulkan risiko *over-segmentation* yang menghambat diagnosis akurat. Penelitian ini bertujuan untuk membangun sebuah sistem cerdas yang dapat mengklasifikasikan dan mendeteksi tumor otak berdasarkan citra MRI secara otomatis, objektif, dan presisi guna memisahkan area tumor secara efektif. Metodologi yang diterapkan melibatkan penggunaan 4.600 citra MRI otak yang melalui tahap pra-pemrosesan berupa konversi ke *grayscale* dan standarisasi ukuran piksel. Citra tersebut kemudian disegmentasikan menggunakan algoritma *K-Means Clustering* berbasis sentroid untuk mengekstrak fitur representatif dengan kompleksitas rendah. Selanjutnya, klasifikasi biner dilakukan menggunakan algoritma *Modified K-Nearest Neighbor* (KNN) yang dioptimalkan melalui mekanisme *Euclidean weighted voting* berbasis kebalikan jarak (*inverse distance*) yang diregularisasi, serta paralelisasi komputasi melalui *Joblib*. Hasil keseluruhan penelitian menunjukkan performa yang sangat kompetitif, di mana sistem berhasil mencapai nilai akurasi sebesar 94,14%, *precision* 96,46%, *recall* 92,37%, dan *F1-score* 94,37%. Kombinasi *K-Means* dan *Modified KNN* ini membuktikan bahwa reduksi fitur berbasis *centroid* mampu menghasilkan deteksi otomatis yang tangguh, mudah diimplementasikan, serta membutuhkan beban komputasi yang jauh lebih rendah dibandingkan dengan pendekatan berbasis *deep learning*.

KATA KUNCI — Tumor Otak, MRI, *K-Means Clustering*, *Modified KNN*, Klasifikasi Citra, Segmentasi Citra

I. PENDAHULUAN

A. LATAR BELAKANG

Tumor otak adalah pertumbuhan sel abnormal yang terbentuk di dalam otak atau komponen di sekitarnya. Kondisi ini diklasifikasikan menjadi jinak (non-kanker) dan ganas (kanker). Tumor otak dapat berkembang dari dua jenis sel otak, yaitu primer dan sekunder [1]. Tumor otak primer adalah tumor yang tumbuh di dalam otak. Tumor otak primer dapat terbentuk dari sel-sel otak dan dikelilingi oleh sel-sel saraf di sekitar otak. Jenis tumor otak ini bisa bersifat jinak maupun ganas. Sedangkan, tumor otak sekunder merupakan jenis tumor otak yang menyebar ke otak dan berasal dari bagian tubuh lain atau disebut sebagai tumor *metastatic*. Kebanyakan tumor otak sekunder bersifat ganas pada otak dan mematikan. Meskipun tumor jinak tidak menyebar dari satu bagian tubuh ke bagian lainnya, tumor otak sekunder hampir selalu bersifat ganas.

Gejala tumor otak dapat bervariasi berdasarkan ukuran, lokasi, dan kecepatan pertumbuhannya. Gejala-gejala khas meliputi sakit kepala yang menetap atau memburuk, terutama di pagi hari, yang merupakan tanda khas dari tumor otak, serta kejang *onset* baru (serangan epilepsi) yang tidak terkait dengan kondisi medis yang diketahui. Selain itu, mual dan muntah dapat terjadi akibat peningkatan tekanan *intrakranial* yang disebabkan oleh tumor. Pencitraan memainkan peran sentral dalam mendeteksi tumor otak.

Magnetic Resonance Imaging (MRI) adalah salah satu teknik pencitraan lanjutan yang paling sering digunakan untuk identifikasi tumor otak. Biasanya MRI digunakan bersamaan dengan pemeriksaan fisik untuk mendeteksi tumor otak. Peralatan radiologi seperti MRI dapat digunakan untuk diagnosa deteksi tumor otak. Sekuens MRI tingkat lanjut seperti T1, T1-

CE, T2, dan FLAIR memberikan wawasan penting mengenai morfologi tumor, edema (pembengkakan), dan kelainan struktural. Namun, ketergantungan pada satu teknik pencitraan saja menghadirkan keterbatasan tertentu. MRI kesulitan mendeteksi struktur padat seperti kalsifikasi penumpukan kalsium dan perdarahan, memiliki waktu akuisisi perekaman gambar yang lebih lama, serta tetap mahal dan kurang mudah diakses di lingkungan medis dengan sumber daya terbatas [1]. Selain itu, variabilitas dalam penyngatan kontras (*contrast enhancement*) turut mempersulit diferensiasi tumor secara presisi. Menganalisis citra MRI secara manual membutuhkan waktu dan keahlian khusus, dan terkadang dapat menghasilkan interpretasi yang subjektif. Teknik yang biasa digunakan adalah biopsi dan pengamatan langsung. Lama waktu biopsi yang menggunakan jarum halus atau *needle biopsy* adalah sekitar 10-15 menit dan hasil biopsi membutuhkan waktu yang lama sekitar 10-15 hari untuk uji laboratorium setelah prosedur dilakukan, sedangkan pengamatan langsung oleh dokter beresiko terjadi kesalahan.

Dalam beberapa tahun terakhir, deteksi tumor otak yang akurat dari citra MRI telah menjadi tantangan kritis dalam analisis citra medis karena berbagai masalah seperti batas tumor yang tidak jelas, dan struktur tumor yang heterogen. Pendekatan yang ada saat ini sering kali mengalami masalah segmentasi berlebihan (*over-segmentation*), ketidakmampuan untuk menangkap ketergantungan jarak jauh (*long-range dependencies*), dan penurunan kinerja pada data volumetrik.

Penggunaan segmentasi citra medis memiliki banyak manfaat dalam perawatan pasien, riset klinis, dan pengembangan teknologi. Oleh karena itu untuk mengatasi

permasalahan tersebut dibutuhkan segmentasi citra yang mampu memberikan hasil klasifikasi. Penelitian ini menerapkan algoritma pembelajaran mesin *K-Means* berbasis sentroid dan klasifikasi menggunakan algoritma *K-Nearest Neighbor* untuk memprediksi keberadaan penyakit kanker secara otomatis dan efisien pada data citra MRI otak.

B. TUJUAN DAN MANFAAT

Tujuan dari penelitian ini adalah untuk membangun sebuah sistem cerdas yang dapat mengklasifikasi dan mendeteksi tumor otak berdasarkan citra *Magnetic Resonance Imaging* (MRI). Untuk mencapai tujuan tersebut, penelitian ini melakukan segmentasi citra menggunakan algoritma *K-Means* berbasis *centroid* dengan metode klasifikasi *K-Nearest Neighbor* (KNN) yang dimodifikasi guna menghasilkan pemisahan area tumor yang lebih presisi, efisien, dan objektif. Lebih lanjut, penelitian ini mengevaluasi efektivitas kombinasi algoritma pembelajaran mesin tersebut dalam mengatasi tantangan kritis pada analisis citra medis, seperti batas tumor yang tidak jelas, struktur jaringan yang heterogen, serta risiko *over-segmentation*. Proses modifikasi dan penyesuaian parameter pada algoritma klasifikasi dikaji secara mendalam untuk meningkatkan kapasitas model dalam menangani kompleksitas data biomedis dan mencapai akurasi serta ketepatan klasifikasi yang lebih tinggi.

C. BATASAN DAN RUANG LINGKUP

Pengujian pada penelitian ini dibatasi pada penggunaan data sekunder publik berupa citra MRI otak, yaitu "Brain Tumor Dataset" milik Preet Viradiya [2] dan "Brain Tumor Multimodal CT and MRI" yang diunduh melalui *platform Kaggle Hub* [3]. Total data citra yang digunakan sebanyak 4.600 gambar, dan pengujian performa sistem dilakukan dengan memilih data secara acak. Hasil klasifikasi pada citra medis dibatasi pada deteksi keberadaan tumor secara biner, yaitu kelas tumor dan sehat.

II. STUDI LITERATUR
A. TUMOR OTAK

Tumor otak adalah pertumbuhan sel yang tidak biasa di dalam atau jaringan sekitar otak. Tumor otak dapat berasal dari otak sendiri atau menyebar dari bagian tubuh lain. Gejala yang disebabkan tumor otak bervariasi berdasarkan lokasi, ukuran, dan laju pertumbuhan tumor tersebut [4]. Gejala tumor otak dapat bervariasi berdasarkan ukuran, lokasi, dan kecepatan pertumbuhannya. Gejala-gejala khas meliputi sakit kepala yang menetap atau memburuk, terutama di pagi hari, yang merupakan tanda khas dari tumor otak, serta kejang *onset* baru (serangan epilepsi) yang tidak terkait dengan kondisi medis yang diketahui berbagai gejala neurologis seperti perubahan penglihatan, kesulitan bicara, hilangnya keseimbangan, kelemahan pada anggota tubuh, serta perubahan memori, konsentrasi, atau kepribadian. Tumor otak dibagi menjadi dua jenis utama, yaitu tumor jinak yang tumbuh secara lambat dan tidak menyebar ke organ di sekitarnya, serta tumor ganas yang tumbuh dengan cepat dan dapat menyebar ke organ di sekitarnya [4].

B. MAGNETIC RESONANCE IMAGING




Magnetic resonance imaging (MRI) merupakan penerapan medis dari fenomena *nuclear magnetic resonance*. MRI memberikan informasi mengenai anatomi dan proses fisiologis dengan menggunakan medan magnet yang kuat, gradien medan magnet, dan gelombang radio untuk menghasilkan gambar tubuh [5]. MRI umumnya mampu menghasilkan pencitraan

tumor otak dengan resolusi yang tinggi dan dapat membedakan jaringan otak dengan baik [4].

C. JENIS SEKUENS MRI TUMOR OTAK

Dalam pencitraan MRI, terdapat tiga jenis sekuens MRI yang digunakan pada pengujian penelitian ini. Salah satunya adalah *T1-weighted imaging* (T1WI) yang menampilkan perbedaan kontras antarjaringan otak. Selain itu, *T2-weighted imaging* (T2WI) digunakan untuk mengukur kandungan air dalam jaringan, pada citra ini, area yang memiliki tumor biasanya tampak sebagai sinyal yang lebih terang dibandingkan jaringan normal. Sekuens MRI lainnya adalah *Fluid-Attenuated Inversion Recovery (FLAIR)*, yaitu modifikasi dari T2WI yang menekan sinyal cairan serebrospinal (CSF) agar jaringan tumor dapat terlihat lebih jelas. Kombinasi ketiga jenis sekuens MRI tersebut memungkinkan proses identifikasi tumor otak yang lebih akurat karena masing-masing jenis sekuens memberikan informasi mengenai struktur anatomi, kandungan cairan, serta perubahan jaringan yang disebabkan oleh tumor [5].

TABEL 1.
JENIS SEKUENS MRI

Modalitas	Hal yang diukur	Temuan tumor umum	Contoh MRI
T1-weighted imaging	Peningkatan kontras	Inti tumor menunjukkan peningkatan kontras; tidak ada peningkatan pada glioma derajat rendah	
T2-weighted imaging	Kandungan air	Sinyal hiperintens pada area edema, tumor, dan kistik	
FLAIR	T2 dengan supresi cairan serebrospinal	Edema peritumoral dan tumor tanpa peningkatan kontras	

D. SEGMENTASI DENGAN K-MEANS

Segmentasi citra merupakan proses membagi citra digital ke dalam beberapa kelompok piksel yang memiliki karakteristik serupa. Salah satu metode segmentasi yang banyak digunakan adalah *K-Means Clustering*, yaitu algoritma pembelajaran tanpa pengawasan (*unsupervised learning*) yang mengelompokkan data ke dalam sejumlah *cluster* berdasarkan tingkat kemiripan data [6]. *K-means* dapat digunakan untuk melakukan segmentasi citra dengan mengelompokkan piksel berdasarkan kesamaan karakteristik [7]. Pada citra MRI otak, proses ini memungkinkan pemisahan area yang memiliki karakteristik berbeda sehingga struktur jaringan pada citra dapat dibedakan ke dalam beberapa

kelompok yang lebih mudah dianalisis pada tahap selanjutnya. Tahapan algoritma *K-MEANS*:

1. Membaca dan *Preprocessing* citra (diubah menjadi *grayscale*, di *resize*, dan diubah menjadi bentuk array 1 dimensi).
2. Menentukan jumlah *cluster* (k).
3. Inisialisasi centroid awal secara acak dari data citra.
4. Menghitung jarak setiap *pixel* dan *centroid* menggunakan *Euclidean Distance*:

$$d(x, y) = \sqrt{\sum_{i=1}^n (x_i - y_i)^2}$$

5. Pengelompokkan semua *pixel* pada gambar ke dalam *cluster*
6. Memperbarui nilai *centroid* dengan memperbarui nilai mean:

$$\mu_k = \frac{1}{N_k} \sum_{q=1}^{N_k} x_q$$
7. Konvergensi: melakukan proses penghitungan jarak, pengelompokan *cluster*, dan pembaruan *centroid* hingga *centroid* stabil atau perubahan nilainya lebih kecil dari nilai toleransi, yaitu $\epsilon = 10^{-4}$
8. Membentuk hasil segmentasi.

E. KLASIFIKASI K-NEAREST NEIGHBOR

K-Nearest Neighbor (KNN) merupakan algoritma *machine learning* yang digunakan untuk menyelesaikan permasalahan klasifikasi maupun regresi. Algoritma ini bekerja berdasarkan prinsip bahwa data baru akan diklasifikasikan berdasarkan kelas, di mana kelas suatu data ditentukan berdasarkan kelas mayoritas di antara sejumlah k tetangga terdekat pada ruang fitur (*feature space*). Prinsip utama pada KNN adalah bahwa data yang memiliki karakteristik serupa cenderung berada pada lokasi yang berdekatan, sehingga proses klasifikasi dilakukan dengan menghitung jarak atau tingkat kedekatan antara data yang diprediksi dengan data yang telah diketahui kelasnya. Algoritma KNN ini bersifat non-parametrik sehingga tidak membutuhkan asumsi terhadap distribusi data.

Namun, algoritma KNN juga memiliki keterbatasan. Akurasi KNN dapat menurun jika jumlah fitur yang digunakan terlalu banyak karena meningkatnya kompleksitas ruang fitur, dan hasil klasifikasi sangat bergantung pada metode pengukuran jarak yang digunakan [8]. Selain itu, KNN tidak dapat secara langsung menunjukkan fitur mana yang paling memengaruhi hasil klasifikasi karena seluruh fitur digunakan secara bersamaan dalam proses perhitungan jarak antar data [9].

Algoritma ini fleksibel karena tidak mengasumsikan distribusi data. KNN menyimpan semua data pelatihan dan baru menghitung jarak saat proses prediksi untuk menentukan label berdasarkan kedekatan, alih-alih membangun model eksplisit selama pelatihan [10]. Hal ini membuatnya dikategorikan sebagai algoritma *lazy learning*. KNN mengukur kemiripan menggunakan metrik jarak seperti Euclidean, Manhattan, atau Minkowski, dengan nilai k optimal yang dipilih melalui validasi silang (*cross-validation*) untuk menghindari *overfitting* pada k kecil atau *underfitting* pada k besar. Adapun tahapan algoritma KNN yaitu:

1. Mengukur kedekatan antar titik data, contohnya jarak Euclidean untuk ruang Euclidean:

$$d(x, y) = \sqrt{\sum_{i=1}^n (x_i - y_i)^2}$$

2. Nilai k : Jumlah tetangga yang dipertimbangkan yang memengaruhi batas Keputusan. Nilai k ganjil sangat direkomendasikan untuk klasifikasi biner guna menghindari hasil seri.
3. Mekanisme voting: Untuk tugas klasifikasi menggunakan suara mayoritas, sedangkan untuk tugas regresi menggunakan nilai rata-rata dari tetangga terdekatnya..
4. Untuk *weighted KNN* (WKNN), Berikan *inverse weight* dari jarak (*distance*) guna meningkatkan akurasi pada data yang tidak seimbang [10].

$$w = \frac{1}{d}$$

Pada algoritma WKNN, sejumlah K titik referensi (*Reference Points*) dengan jarak terkecil juga dipilih, namun dengan menggunakan pendekatan berbobot (*weighted*). Mengingat bahwa jarak antara titik-titik referensi yang dipilih terhadap titik uji berbeda-beda, maka bobot yang diberikan pada masing-masing titik referensi tersebut juga berbeda. Bobot dari titik-titik referensi yang dipilih dapat dihitung menggunakan persamaan di atas, di mana nilai bobot tersebut berbanding terbalik dengan jarak (d). Algoritma WKNN menghasilkan tingkat akurasi pemosisian yang lebih baik dibandingkan dengan algoritma KNN, serta merupakan algoritma pencocokan yang paling sering digunakan [11].

F. PARALELISASI

Dalam analisis citra medis berdimensi tinggi seperti MRI, optimasi pemrosesan sangat krusial untuk mengatasi keterbatasan daya komputasi. Pendekatan ekstraksi fitur menggunakan algoritma *K-Means* terbukti efisien tidak hanya untuk segmentasi, tetapi juga sebagai metode reduksi dimensi dengan mengekstrak nilai sentroid klaster. Representasi ringkas ini secara signifikan meminimalkan penggunaan memori komputasi dan mencegah *overfitting* tanpa mengorbankan presisi deteksi batas tumor [12].

Selain reduksi dimensi pada level algoritma, optimasi waktu eksekusi juga mutlak diperlukan pada tahap pra-pemrosesan data (*preprocessing*). Memproses dan mengekstrak fitur dari ribuan citra MRI membutuhkan waktu yang sangat tinggi dan rentan mengalami *bottleneck* jika dijalankan secara sekuensial. Oleh karena itu, penerapan arsitektur komputasi paralel (*parallel processing*) berbasis *multi-core* CPU seperti pemanfaatan mekanisme *joblib* menjadi standar modern untuk memecah beban kerja independen ke seluruh inti prosesor secara bersamaan. Penelitian terdahulu menunjukkan bahwa implementasi komputasi paralel pada tahap awal pemrosesan citra medis mampu mempercepat waktu eksekusi secara drastis hingga 4-5 kali lipat dibandingkan metode konvensional [13].


G. PERBANDINGAN DENGAN PENELITIAN TERDAHULU

Penelitian-penelitian terdahulu dalam deteksi tumor otak umumnya menggunakan metode berbasis *deep learning* seperti *Convolutional Neural Network* (CNN), *ResNet*, *DenseNet*, *U-Net*, dan *Vision Transformer* [14]. Metode-metode tersebut mampu menghasilkan akurasi yang tinggi, namun memerlukan jumlah data yang besar, waktu pelatihan yang lama, serta perangkat keras dengan kemampuan komputasi tinggi. Metode yang diusulkan pada penelitian ini menawarkan pendekatan yang lebih sederhana dengan mengombinasikan segmentasi *K-Means* dan klasifikasi KNN yang dimodifikasi menggunakan mekanisme *weighted voting*. Keunggulan pendekatan ini adalah kebutuhan komputasi yang relatif rendah, implementasi yang mudah, serta kemampuan interpretasi yang baik. Selain itu, penggunaan *centroid* hasil segmentasi sebagai fitur

memungkinkan reduksi kompleksitas data tanpa menghilangkan karakteristik utama citra MRI.

III. METODE ANALISIS

A. DATASET



Gambar 1. Contoh gambar dari dataset.

Dataset yang digunakan dalam penelitian ini adalah *Preet Viradiya Brain Tumor Dataset* yang tersedia secara publik (<https://www.kaggle.com/datasets/preetviradiya/brian-tumor-dataset> diakses pada Mei 2026). Dataset ini terdiri dari hasil pemindaian MRI otak yang dikategorikan ke dalam kelompok sehat dan kelompok yang terkena tumor. Dataset ini berisi sejumlah besar gambar dan memiliki proporsi yang seimbang, dengan 55% gambar menunjukkan visualisasi tumor dan 45% sisanya merepresentasikan hasil pemindaian otak yang sehat [15]. Dataset terdiri atas sekitar 4.600 citra MRI otak yang terbagi menjadi dua kelas, yaitu *Tumor* dan *Healthy*. Seluruh eksperimen dilakukan menggunakan bahasa pemrograman *Python* pada *Google Colab* dengan bantuan *library OpenCV, NumPy, Scikit-Learn, Joblib, Matplotlib*, dan *KaggleHub*.

B. DATA PREPROCESSING

Pengujian diawali dengan proses akuisisi data menggunakan dataset *Brain Tumor Dataset* yang diperoleh melalui *Kaggle*. Setelah itu, setiap citra MRI melalui tahap pra-pemrosesan (*preprocessing*), yang bertujuan untuk menstandarkan format data dan mengurangi kompleksitas komputasi pada tahapan pengujian selanjutnya. Pada tahap awal, seluruh citra MRI mentah dikonversi dari format warna *Red Green Blue* (RGB) menjadi skala keabuan (*grayscale*). Langkah ini sangat krusial karena analisis morfologi tumor pada MRI umumnya bergantung pada perbedaan intensitas piksel struktural, sehingga reduksi saluran warna tidak hanya mempertahankan integritas informasi visual, tetapi juga secara signifikan menurunkan kompleksitas komputasi.

Selanjutnya, seluruh citra diskalakan secara seragam (*resizing*) ke resolusi standar 256×256 piksel. Penyeragaman dimensi ini adalah langkah penting untuk memitigasi efek variabilitas dari berbagai protokol akuisisi citra dan ukuran asli yang berbeda-beda. Hal ini memastikan bahwa algoritma klastering menerima *input* spasial yang konsisten di seluruh *dataset*, sehingga memfasilitasi performa model yang stabil dan merata.

Tahap berikutnya penyesuaian struktur data matematis. Matriks citra dua dimensi (2D) diubah bentuknya (*flattening*) menjadi larik vektor satu dimensi (1D). Transformasi ini mutlak diperlukan karena algoritma segmentasi *K-Means* memproses setiap piksel sebagai titik fitur independen dalam ruang pencarian. Lebih lanjut, nilai-nilai piksel tersebut dikonversi ke dalam format angka pecahan presisi tunggal (*float32*). Konversi

tipe data ini memainkan peran kritis dalam memastikan stabilitas numerik dan presisi komputasi, khususnya saat model menghitung metrik jarak Euclidean (*Euclidean distance*) antara piksel dan sentroid klaster.


C. SEGMENTASI K-MEANS

Proses segmentasi diawali dengan menentukan jumlah klaster optimal, yang pada penelitian ini ditetapkan sebanyak tiga klaster ($k=3$). Pemilihan nilai ini secara empiris bertujuan untuk merepresentasikan tiga kelompok intensitas utama pada citra MRI otak, yaitu area latar belakang (*background*), jaringan otak sehat, dan area tumor yang umumnya memiliki pola intensitas berbeda (*hiperintens* atau *hipointens*). Pada tahap inisialisasi, tiga nilai piksel dipilih secara acak dari vektor citra satu dimensi (1D) tanpa pengembalian (*without replacement*) untuk bertindak sebagai titik pusat awal atau sentroid (*centroids*).

Setelah sentroid awal ditetapkan, algoritma memasuki fase iteratif yang terdiri dari proses penugasan (*assignment*) dan pembaruan (*update*). Pada langkah penugasan, metrik jarak Euclidean untuk mengukur proksimitas antara setiap piksel tunggal dengan ketiga sentroid. Setiap piksel kemudian diklasifikasikan ke dalam klaster yang memiliki jarak sentroid terdekat (nilai minimum). Langkah ini sangat esensial untuk memastikan bahwa piksel-piksel dengan derajat kecerahan visual yang serupa dikelompokkan secara konsisten ke dalam entitas yang sama.

Selanjutnya, pembaruan posisi sentroid dilakukan dengan menghitung nilai rata-rata (*mean*) intensitas dari seluruh piksel yang tergabung dalam masing-masing klaster. Untuk menjaga stabilitas model dan mencegah terjadinya singularitas komputasi, algoritma juga dirancang untuk menangani klaster kosong (*empty clusters*) dengan cara mengalokasikan ulang sentroid ke titik piksel acak yang baru.

Siklus penugasan dan pembaruan ini diulang secara berkesinambungan hingga algoritma mencapai status konvergen. Konvergensi didefinisikan sebagai kondisi di mana perubahan absolut posisi seluruh sentroid antar-iterasi berada di bawah ambang batas toleransi yang sangat ketat (10^{-4}), atau saat proses komputasi telah menyentuh batas maksimum 100 iterasi. Penggunaan kriteria penghentian ini krusial untuk menjamin bahwa proses pengelompokan telah mencapai titik stabil dan representasi area target sudah optimal. Pada tahap akhir, nilai intensitas asli dari setiap piksel digantikan dengan nilai sentroid akhirnya, dan matriks data dikonversi kembali menjadi citra dua dimensi (2D). Transformasi final ini menghasilkan citra tersegmentasi yang dengan jelas menyoroti batas-batas area tumor, sehingga meningkatkan akurasi dan efisiensi untuk tahapan ekstraksi fitur dan klasifikasi selanjutnya.



Gambar 2. Hasil segmentasi K-MEANS.

D. KLASIFIKASI MODIFIED KNN

Pada tahap ini adalah proses klasifikasi menggunakan algoritma *Modified KNN*. Berbeda dengan KNN konvensional yang menggunakan vektor fitur tunggal, metode yang diusulkan menghitung kemiripan antar citra berdasarkan *centroid* hasil segmentasi *K-Means*. Jarak antara *centroid* citra uji dan seluruh *centroid* citra pelatihan dihitung menggunakan jarak Euclidean, kemudian diurutkan dari nilai terkecil hingga terbesar. Sebanyak tiga tetangga terdekat ($k = 3$) dipilih untuk menentukan kelas citra. Agar tetangga yang memiliki jarak lebih dekat memberikan pengaruh yang lebih besar terhadap hasil klasifikasi, kelas akhir ditentukan berdasarkan total bobot terbesar, yaitu tumor atau sehat. Proses penentuan kelas dilakukan menggunakan mekanisme *weighted voting*, di mana setiap tetangga diberikan bobot berdasarkan persamaan:

$$w = \frac{1}{d + \epsilon}$$

Pada persamaan tersebut w adalah bobot dan d adalah jarak. Konstanta ϵ (epsilon) adalah bilangan positif mendekati 0 ($\epsilon=10^{-6}$) penggunaan konstanta ϵ merupakan teknik regularisasi penghalus yang digunakan untuk mencegah kesalahan pembagian dengan nol (tidak terdefinisi) dan memastikan stabilitas numerik, selama normalisasi pembagian [16]. Pada akhirnya, kelas dengan akumulasi bobot tertinggi akan ditetapkan sebagai hasil prediksi. Strategi *weighted voting* ini memainkan peran kritical dalam menghasilkan keputusan klasifikasi yang adaptif, objektif, dan tangguh terhadap variabilitas data citra medis.

E. PARALELISASI

Pemrosesan citra medis berdimensi tinggi dalam jumlah masif umumnya membutuhkan beban komputasi yang sangat besar dan waktu eksekusi yang lama. Untuk mengatasi hambatan komputasi tersebut, teknik paralelisasi diimplementasikan guna meningkatkan efisiensi sistem secara keseluruhan. Dalam penelitian ini, pustaka *Joblib* dimanfaatkan untuk mendistribusikan beban kerja secara simultan ke seluruh inti prosesor (CPU cores) yang tersedia melalui penetapan parameter $n_jobs = -1$.

Pendekatan komputasi paralel ini diaplikasikan secara spesifik pada dua tahapan krusial. Pertama, paralelisasi diterapkan pada fase ekstraksi fitur, di mana proses pengerjaan algoritma *K-Means* untuk mencari titik sentroid pada ribuan citra latih dan citra uji dieksekusi secara bersamaan. Kedua, paralelisasi juga diimplementasikan pada fase klasifikasi, di mana prediksi label menggunakan *Modified KNN* dikalkulasi secara serentak untuk seluruh data uji. Implementasi langkah ini sangat esensial karena memungkinkan sistem memproses data secara independen dan simultan, yang pada akhirnya secara drastis mereduksi total waktu eksekusi program tanpa mengurangi integritas maupun akurasi dari hasil komputasi analitik.

F. METODE EVALUASI

Kinerja model evaluasi dikalkulasi secara komprehensif menggunakan beberapa metrik standar guna memberikan penilaian yang objektif terhadap kapabilitas klasifikasi sistem. Metrik-metrik tersebut meliputi *Accuracy*, yang merepresentasikan persentase total citra yang berhasil diklasifikasikan dengan benar dari keseluruhan dataset. Untuk memastikan analisis yang mendalam pada setiap kelas, metrik *Sensitivity* (atau *Recall*) diterapkan untuk mengukur

kemampuan algoritma dalam mengidentifikasi kasus positif (tumor) secara tepat. Selanjutnya, metrik *Precision* digunakan untuk menghitung proporsi identifikasi positif yang benar-benar akurat, dan *F1-Score* dihitung sebagai rata-rata harmonik antara *precision* dan *recall* untuk memberikan satu metrik evaluasi yang seimbang. Metrik-metrik ini memberikan penilaian yang komprehensif terhadap kemampuan klasifikasi model, memastikan bahwa model tidak hanya berkinerja baik secara rata-rata, tetapi juga secara efektif mampu membedakan antara kasus tumor dan non-tumor. Oleh karena itu, metrik-metrik utama tersebut disajikan dalam persamaan berikut:

$$Accuracy = \frac{TP + TN}{TP + TN + FP + FN}$$

$$Precision = \frac{TP}{TP + FP}$$

$$Recall = \frac{TP}{TP + FN}$$

$$F1\ Score = 2 \times \frac{Precision \times Recall}{Precision + Recall}$$

IV. HASIL DAN PEMBAHASAN

A. EVALUASI PERFORMA

Berdasarkan hasil pengujian pada data testing, metode yang diusulkan, yakni kombinasi algoritma *K-Means* dan *Modified K-Nearest Neighbors* (KNN) memperoleh tingkat akurasi yang mengesankan sebesar 94,14%. Hal ini mendemonstrasikan kemampuan model yang luar biasa dalam membedakan secara efektif antara citra MRI yang mengandung tumor dan citra MRI sehat. Konfigurasi spesifik ini memungkinkan model untuk mengekstraksi fitur-fitur representatif secara komprehensif melalui pemanfaatan *centroid* hasil segmentasi citra. Kombinasi tersebut dipadukan dengan mekanisme *weighted voting* pada proses klasifikasi, yang terbukti secara krusial mampu mengintegrasikan informasi spasial dan jarak untuk menghasilkan keputusan akhir yang sangat presisi dan terinformasi dengan baik.

Tingginya metrik performa model ini ditunjukkan oleh nilai presisi sebesar 96,46%, *recall* sebesar 92,37%, dan skor F1 sebesar 94,37%. Nilai presisi yang sangat tinggi mengindikasikan efektivitas model yang luar biasa dalam mendeteksi *true positives*, sekaligus menekan angka *false positives*. Dalam konteks klinis, hal ini sangat krusial; akurasi dan presisi yang tinggi meminimalkan risiko pasien menerima diagnosis positif palsu yang dapat berujung pada kecemasan yang tidak perlu serta prosedur invasif yang tidak diwajibkan. Pendekatan ini menghasilkan sistem yang relatif sederhana, mudah diimplementasikan, dan memiliki kebutuhan komputasi yang jauh lebih rendah dibandingkan metode berbasis *deep learning*, namun tetap mampu memberikan performa klasifikasi yang sangat kompetitif.

B. PERBANDINGAN PERFORMA DENGAN MODEL LAIN


Berikut adalah perbandingan model yang diusulkan dengan metode lainnya.

TABEL 2.
PERBANDINGAN METRIK EVALUASI MODEL

Model	Accuracy	Precision	Recall	F1-Score
<i>KNN Modified</i>	94,14%	96,46%	92,37%	94,37%
<i>KNN Paralel (Library)</i>	71,40%	74,44%	70,34%	72,33%
<i>KNN Modified (dataset lain)</i>	86,40%	90,24%	86,70%	88,41%

Pada model kedua, dimana menggunakan klasifikasi KNN secara paralel dengan *library Scikit-learn* standar. Model hanya mencapai akurasi rata-rata sebesar 71,40%. Konfigurasi ini tidak mampu menyaingi ketajaman ekstraksi fitur dari model usulan, sehingga menghasilkan performa generalisasi yang kurang optimal. Model ketiga, dilakukan pengujian pada *dataset* lain, yaitu “*Brain Tumor Multimodal CT and MRI*”, dimana pengujian dilakukan dengan mengambil dataset MRI nya saja. Pada skala lebih yang lebih besar, yaitu sebanyak 5000 data pendukung, model mencapai akurasi sebesar 86.40%. Meskipun evaluasi skala besar ini membuktikan bahwa metode paralel dapat menangani data masif dengan performa klasifikasi yang cukup seimbang (*well-balanced*), performa puncaknya masih berada di bawah ketepatan diagnosis dari arsitektur *K-Means* dan *Modified KNN* yang diusulkan.

C. ANALISIS CONFUSION MATRIX




Gambar 3. Hasil Confusion Matrix

Berdasarkan hasil *confusion matrix*, model berhasil mengklasifikasikan 200 citra sehat (*Healthy*) dengan benar sebagai sehat (*true negative*) dan 218 citra tumor (*Tumor*) dengan benar sebagai tumor (*true positive*). Di sisi lain, terdapat 8 citra sehat yang salah diklasifikasikan sebagai tumor (*false positive*) serta 18 citra tumor yang salah diklasifikasikan sebagai sehat (*false negative*). Hasil tersebut menunjukkan bahwa sebagian besar citra pada kedua kelas berhasil diidentifikasi dengan benar oleh model. Jumlah kesalahan klasifikasi pada kelas sehat relatif rendah, yaitu hanya 8 citra, yang mengindikasikan bahwa model memiliki kemampuan yang baik dalam mengenali citra sehat. Namun, masih terdapat 18 citra tumor yang terklasifikasi sebagai sehat. Temuan ini menunjukkan bahwa kesalahan klasifikasi lebih banyak terjadi pada citra tumor dibandingkan citra sehat. Secara keseluruhan, nilai pada *confusion matrix* memperlihatkan bahwa model mampu membedakan citra MRI tumor dan sehat dengan tingkat ketepatan yang tinggi, ditunjukkan oleh dominasi nilai pada diagonal utama matriks dibandingkan nilai kesalahan di luar diagonal.


Berdasarkan keseluruhan hasil eksperimen, kombinasi algoritma *K-Means* dan *Modified KNN* terbukti mampu digunakan untuk mendeteksi tumor otak pada citra MRI secara otomatis. Kontribusi utama penelitian ini terletak pada pemanfaatan *centroid* hasil segmentasi sebagai fitur representatif citra serta penggunaan mekanisme *weighted voting* pada proses klasifikasi. Pendekatan tersebut menghasilkan

sistem yang relatif sederhana, mudah diimplementasikan, dan memiliki kebutuhan komputasi yang lebih rendah dibandingkan metode berbasis *deep learning*, namun tetap mampu memberikan performa klasifikasi yang kompetitif pada dataset yang digunakan dalam penelitian ini.



Gambar 4. Hasil Confusion Matrix

Pada model KNN Paralel (*Library*) mencatatkan 151 *true negatives* dan 166 *true positives*, diiringi dengan lonjakan kesalahan berupa 57 *false positives* dan 70 *false negatives*. Hal ini mengindikasikan kurangnya kemampuan model *baseline* ini dalam menyaring fitur-fitur kompleks yang menandakan keberadaan tumor secara pasti.



Gambar 5. Hasil Confusion Matrix

Pada pengujian dataset “*Brain Tumor Multimodal CT and MRI*”, matriks menunjukkan 1719 *true negatives* dan 2601 *true positives*, dengan 281 *false positives* dan 399 *false negatives*. Model ini merefleksikan performa yang cukup tangguh dalam mendeteksi tumor dalam jumlah kasus yang masif, namun proporsi tingkat kesalahannya tetap lebih besar dibandingkan dengan tingkat efisiensi yang ditawarkan oleh pendekatan usulan.

D. PERBANDINGAN DENGAN PENELITIAN TERDAHULU

Table 3.
PERBANDINGAN DENGAN PENELITIAN TERDAHULU
MENGUNAKAN DATASET YANG SAMA

Peneliti	Tahun	Klasifikasi	Accuracy	Recall
Zahoor et al. [17]	2024	Res-BRNet (CNN)	98.22%	98.11%
Mandle et al. [18]	2022	VGG-19 CNN	99.83%	97.82–98.87%
Zeineldin et al. [19]	2022	Multimodal CNN	94.2%	92.5%
Xue et al. [20]	2022	Multimodal CNN	93.0%	91.0%
Projek ini	2026	Modified KNN	94,14%	96,46%

Baik pada model yang diusulkan oleh Zahoor et al. [17] maupun Mandle et al. [18] menyajikan pendekatan *deep learning* yang mencapai hasil kompetitif dalam klasifikasi tumor otak menggunakan citra MRI. Zahoor et al. mengusulkan Res-BRNet, sebuah arsitektur baru yang menggabungkan blok regional dan *residual*, yang mencapai akurasi sebesar 98,22% dan *recall* 98,11%. Demikian pula, model Mandle et al., yang berbasis pada arsitektur VGG-19, melaporkan akurasi yang mengesankan sebesar 99,83%, dengan tingkat *recall* antara 97,82% hingga 98,87% untuk berbagai jenis tumor. Hasil-hasil ini sangat berdekatan dan menunjukkan efektivitas kedua model dalam tugas tersebut. Namun, perbedaan utama antara pendekatan-pendekatan tersebut dengan CNN teroptimasi yang diusulkan dalam penelitian ini terletak pada kompleksitas arsitekturnya. Kedua penelitian di atas mempertimbangkan model berlapis ganda (*multi-layered*) dan mendalam yang, meskipun tangguh, menuntut sumber daya komputasi yang substansial karena tingkat kedalaman serta jumlah operasi yang diperlukan untuk ekstraksi fitur dan klasifikasi. Sebaliknya, CNN teroptimasi dalam penelitian ini mencapai performa yang sebanding atau bahkan lebih unggul dengan arsitektur yang kurang kompleks, sehingga mengurangi beban komputasi. Hal ini menjadikan model tersebut lebih cocok untuk lingkungan dengan sumber daya komputasi yang terbatas, menawarkan keseimbangan yang praktis antara akurasi dan efisiensi.

Dalam penelitian oleh Zeineldin et al. [19], para penulis mencapai akurasi sebesar 94,2% dan sensitivitas 92,5% dalam deteksi tumor otak. Mereka menggunakan *convolutional neural network* multimodal yang mengintegrasikan berbagai modalitas pencitraan MRI. Sebagai perbandingan, model terbaik pada proyek saat ini mencapai akurasi sebesar 97,5% dan sensitivitas 99,2%, jauh melampaui hasil Zeineldin dkk. Perbedaan ini dapat dikaitkan dengan kesederhanaan dan efisiensi arsitektur yang dioptimalkan, serta pemilihan dan penyesuaian (*tuning*) *hyperparameter* yang cermat. Selain itu, penggunaan teknik pra-pemrosesan tingkat lanjut dalam penelitian ini mungkin telah berkontribusi dalam meningkatkan kualitas citra masukan, yang pada gilirannya meningkatkan performa model.

Pada penelitian yang dilakukan oleh Xue et al. [20] melaporkan akurasi rata-rata sebesar 93,0% dan sensitivitas 91,0% dalam beberapa studi. Studi-studi tersebut mencakup berbagai pendekatan, termasuk jaringan konvolusional mendalam (*deep convolutional networks*) dan teknik *machine learning* multimodal. Hasil yang diperoleh dalam penelitian ini, dengan akurasi 97,5% dan sensitivitas 99,2%, lebih unggul. Hal ini mungkin disebabkan oleh spesifisitas *dataset* yang digunakan serta teknik pra-pemrosesan dan optimasi tingkat lanjut yang diterapkan. Penggunaan citra yang bersih dan berskala baik

memungkinkan model untuk mempelajari fitur-fitur yang relevan untuk deteksi tumor dengan lebih baik.

Model-model yang dikembangkan dalam penelitian ini menunjukkan performa yang sangat baik, baik dari segi akurasi maupun sensitivitas. Keunggulan model-model ini pada metrik-metrik kritis tersebut, bersama dengan kemampuannya untuk menggeneralisasi secara efektif pada *dataset* eksternal dan mempertahankan waktu eksekusi wajar yang sesuai untuk sistem layanan kesehatan, menyoroti efektivitas dari model yang diusulkan. Hal ini menunjukkan potensi kuatnya model untuk implementasi klinis di dunia nyata, di mana model-model ini dapat memberikan diagnosis yang presisi dan dapat diandalkan, yang pada akhirnya berkontribusi pada peningkatan hasil perawatan bagi pasien tumor otak.

V. KESIMPULAN DAN SARAN
A. KESIMPULAN

Penelitian ini berhasil mengembangkan sistem deteksi tumor otak berbasis citra MRI dengan mengombinasikan algoritma segmentasi *K-Means* dan algoritma klasifikasi *Modified KNN*. Proses segmentasi menggunakan *K-Means* mampu mengelompokkan piksel citra berdasarkan karakteristik intensitasnya dan menghasilkan *centroid* yang digunakan sebagai fitur representatif pada tahap klasifikasi. Pendekatan tersebut memungkinkan proses pengolahan data dilakukan dengan kompleksitas yang lebih rendah dibandingkan penggunaan seluruh piksel citra secara langsung.

Berdasarkan hasil pengujian, metode yang diusulkan memperoleh nilai *accuracy* sebesar 94,14%, *precision* sebesar 96,46%, *recall* sebesar 92,37%, dan *F1-score* sebesar 94,37%. Hasil *confusion matrix* menunjukkan bahwa model berhasil mengklasifikasikan 200 citra sehat dan 218 citra tumor dengan benar, dengan jumlah kesalahan klasifikasi yang relatif kecil. Hasil tersebut menunjukkan bahwa kombinasi *K-Means* dan *Modified KNN* mampu membedakan citra MRI tumor dan sehat dengan tingkat ketepatan yang tinggi.

Secara keseluruhan, tujuan penelitian untuk membangun sistem klasifikasi dan deteksi tumor otak berbasis citra MRI telah tercapai. Hasil penelitian menunjukkan bahwa penggunaan *centroid* hasil segmentasi sebagai fitur masukan serta penerapan mekanisme *weighted voting* pada KNN dapat memberikan performa klasifikasi yang baik. Dengan demikian, metode yang diusulkan dapat menjadi alternatif yang sederhana, efisien, dan mudah diimplementasikan untuk membantu proses deteksi tumor otak secara otomatis.

REFERENSI

[1] S. Kar and P. K. Singh, "MBTC-Net: Multimodal brain tumor classification from CT and MRI scans using deep neural network with multi-head attention mechanism," *Med. Nov. Technol. Devices*, vol. 27, p. 100382, Sep. 2025, doi: 10.1016/J.MEDNTD.2025.100382.

[2] "Brian Tumor Dataset." Accessed: Jun. 03, 2026. [Online]. Available: <https://www.kaggle.com/datasets/preetviradiya/brian-tumor-dataset>

[3] "Brain tumor multimodal image (CT & MRI)." Accessed: Jun. 03, 2026. [Online]. Available: <https://www.kaggle.com/datasets/murtozalikhon/brain-tumor-multimodal-image-ct-and-mri>

[4] U. Raghavendra et al., "Brain tumor detection and screening using artificial intelligence techniques: Current trends and future perspectives," *Comput. Biol. Med.*, vol. 163, p. 107063, Sep. 2023, doi: 10.1016/J.COMPBIOMED.2023.107063.

[5] J. Fares, Y. Wan, Y. Li, T. Matys, T. A. Carpenter, and S. J. Price, "Magnetic Resonance Imaging Physics in Brain Tumor Imaging: A Primer for Neurosurgeons," *World Neurosurg.*, vol. 204, p. 124591, Dec. 2025, doi: 10.1016/J.WNEU.2025.124591.

[6] A. M. Ikotun, A. E. Ezugwu, L. Abualigah, B. Abuhaija, and J. Heming, "K-means clustering algorithms: A comprehensive review, variants

- analysis, and advances in the era of big data,” *Inf. Sci. (N. Y.)*, vol. 622, pp. 178–210, Apr. 2023, doi: 10.1016/J.INS.2022.11.139.
- [7] P. Shan, “Image segmentation method based on K-mean algorithm,” *EURASIP Journal on Image and Video Processing 2018 2018:1*, vol. 2018, no. 1, pp. 81–, Sep. 2018, doi: 10.1186/S13640-018-0322-6.
- [8] V. B. S. Prasath *et al.*, “Distance and Similarity Measures Effect on the Performance of K-Nearest Neighbor Classifier -- A Review,” *Big Data*, vol. 7, no. 4, pp. 221–248, Sep. 2019, doi: 10.1089/big.2018.0175.
- [9] T. Elsten and M. de Rooij, “SUBiNN: a stacked uni- and bivariate kNN sparse ensemble,” *Advances in Data Analysis and Classification 2021 16:4*, vol. 16, no. 4, pp. 847–874, Oct. 2021, doi: 10.1007/S11634-021-00462-7.
- [10] H. I. Abdalla and A. A. Amer, “Enhancing data classification using locally informed weighted k-nearest neighbor algorithm,” *Expert Syst. Appl.*, vol. 276, p. 126942, Jun. 2025, doi: 10.1016/J.ESWA.2025.126942.
- [11] X. Peng, R. Chen, K. Yu, F. Ye, and W. Xue, “An Improved Weighted K-Nearest Neighbor Algorithm for Indoor Localization,” *Electronics 2020, Vol. 9, Page 2117*, vol. 9, no. 12, p. 2117, Dec. 2020, doi: 10.3390/ELECTRONICS9122117.
- [12] J. Amin, M. Sharif, A. Haldorai, M. Yasmin, and R. S. Nayak, “Brain tumor detection and classification using machine learning: a comprehensive survey,” *Complex & Intelligent Systems 2021 8:4*, vol. 8, no. 4, pp. 3161–3183, Nov. 2021, doi: 10.1007/S40747-021-00563-Y.
- [13] I. Wahlang, P. Sharma, S. Sanyal, G. Saha, and A. Kumar Maji, “Deep learning techniques for classification of brain MRI,” 2020. [Online]. Available: <https://www.britannica.com/science/>
- [14] P. Sharma, D. R. Nayak, B. K. Balabantaray, M. Tanveer, and R. Nayak, “A survey on cancer detection via convolutional neural networks: Current challenges and future directions,” *Neural Networks*, vol. 169, pp. 637–659, Jan. 2024, doi: 10.1016/J.NEUNET.2023.11.006.
- [15] R. Martínez-Del-Río-Ortega, J. Civit-Masot, F. Luna-Perejón, and M. Domínguez-Morales, “Brain Tumor Detection Using Magnetic Resonance Imaging and Convolutional Neural Networks,” *Big Data and Cognitive Computing*, vol. 8, no. 9, p. 123, Sep. 2024, doi: 10.3390/BDCC8090123/S1.
- [16] S. Song *et al.*, “Research on a working face gas concentration prediction model based on LASSO-RNN time series data,” *Heliyon*, vol. 9, no. 4, Apr. 2023, doi: 10.1016/j.heliyon.2023.e14864.
- [17] M. M. Zahoor *et al.*, “Brain Tumor MRI Classification Using a Novel Deep Residual and Regional CNN,” *Biomedicines*, vol. 12, no. 7, Jul. 2024, doi: 10.3390/BIOMEDICINES12071395.
- [18] A. K. Mandle, S. P. Sahu, and G. P. Gupta, “CNN-Based Deep Learning Technique for the Brain Tumor Identification and Classification in MRI Images,” <https://services.igi-global.com/resolvedoi/resolve.aspx?doi=10.4018/IJSSCI.304438>, vol. 14, no. 1, pp. 1–20, Jan. 1AD, doi: 10.4018/IJSSCI.304438.
- [19] R. A. Zeineldin, M. E. Karar, O. Burgert, and F. Mathis-Ullrich, “Multimodal CNN Networks for Brain Tumor Segmentation in MRI: A BraTS 2022 Challenge Solution,” *Lecture Notes in Computer Science (including subseries Lecture Notes in Artificial Intelligence and Lecture Notes in Bioinformatics)*, vol. 13769 LNCS, pp. 127–137, Dec. 2022, doi: 10.1007/978-3-031-33842-7_11.
- [20] H. Xue, Y. Yao, and Y. Teng, “Multi-modal tumor segmentation methods based on deep learning: a narrative review,” *Quant. Imaging Med. Surg.*, vol. 14, no. 1, pp. 1122–1140, Jan. 2024, doi: 10.21037/QIMS-23-818/COIF.

LAMPIRAN

[Projek Konsep Dasar Kecerdasan Artifisial - Colab](#)

[Projek Konsep Dasar Kecerdasan Artifisial - Github](#)